

Informe Final del Proyecto: Clasificación de la Calidad del Aire

1. ¿Qué hicimos? En este proyecto, el objetivo fue crear un modelo que nos ayudara a predecir si la calidad del aire era buena o mala. Usamos un dataset público con información real sobre la contaminación del aire. A lo largo del trabajo, analizamos los datos, los preparamos y probamos dos modelos diferentes para ver cuál funcionaba mejor.

2. ¿De dónde sacamos los datos? El dataset que usamos se llama "Air Quality" y lo descargamos del repositorio UCI. Tiene más de 9000 registros y mide distintos contaminantes como monóxido de carbono (CO), óxidos de nitrógeno (NOx), hidrocarburos, entre otros. Las mediciones fueron tomadas entre 2004 y 2005 en Italia.

3. Explorando los datos Antes de hacer cualquier modelo, revisamos bien los datos. Vimos qué columnas había, si faltaban datos, y cómo se comportaban las variables. También hicimos gráficos como histogramas y mapas de calor para ver si había relaciones interesantes entre las variables. Algo que notamos fue que el CO y el NOx estaban bastante relacionados.

4. Preparando los datos Como en casi todos los datasets reales, había datos faltantes, así que completamos esos espacios usando el promedio. Después, creamos una nueva columna llamada "calidad_aire". Esta columna nos dice si el aire es "bueno" o "malo", dependiendo del valor de CO:

- Si $CO < 2$, decimos que el aire es "bueno"
- Si $CO \geq 2$, lo consideramos "malo"

Dividimos los datos en conjuntos de entrenamiento y prueba, y normalizamos las variables para que todos los modelos pudieran funcionar bien.

5. Probamos dos modelos

- **Random Forest:** Este modelo funciona creando muchos árboles de decisión. Ajustamos sus parámetros con GridSearchCV para encontrar la mejor combinación. Nos dio una muy buena precisión, de más del 85%.
- **K-Nearest Neighbors (KNN):** También probamos con este modelo que clasifica los datos mirando los más parecidos (vecinos). Aunque tuvo un buen rendimiento, fue un poco menor que el de Random Forest.

6. ¿Cuál fue mejor? Ambos modelos fueron buenos, pero Random Forest se comportó mejor en general. Tenía mejor precisión, mejor balance entre clases y

además su curva de aprendizaje era más estable. KNN fue más sensible a los cambios.

7. Conclusiones El modelo de Random Forest fue el más confiable para predecir la calidad del aire. Si seguimos mejorando, podríamos usar otros algoritmos como XGBoost o incluso redes neuronales. También sería útil tener datos más actuales y variados.

8. ¿Dónde está todo? Todos los archivos de este proyecto (código, dataset, análisis y este informe) están disponibles en el repositorio de GitHub que creamos para la materia.